

IL PROBLEMA DEL SONDAGGISTA

Immaginiamo di essere un sondaggista che deve fare una indagine statistica. Quante persone dovrebbe intervistare per ottenere una percentuale vicina al valore vero?

Teoricamente tutte, ma questo non è possibile...

Sia f la frazione di persone che soddisfa un evento A .

Il problema del sondaggista è stimare f

Il sondaggista seleziona un campione di n persone a caso. Per la persona i -esima estratta poniamo il quesito e registriamo la risposta...

$$X_i = \begin{cases} 1 & \text{se } A \text{ è verificato per la } i\text{-esima persona} \\ 0 & \text{altrimenti} \end{cases}$$

per $i = 1, \dots, n$

Quindi $X_i \sim \text{Bern}(f)$

Supponiamo, inoltre, che le X_i sono i.i.d

$$\text{Allora } P_{X_i}(1) = f, \quad E[X_i] = f \quad \text{e} \\ \text{var}[X_i] = f(1-f)$$

calcoliamo la media campionaria...


$$M_n = \frac{\sum_{i=1}^n X_i}{n} = \hat{f} \quad \leftarrow \text{STIMA DI } f$$

Per la **LEGGE DEI GRANDI NUMERI**, $\hat{f}$
approssima f per n abbastanza grande

Il problema è che il sondaggista vorrebbe chiedere
a un numero minimo di persone

L'obiettivo è cadere
nell'intervallo giusto
con alta probabilità
(ad esempio 95%)

→ la stima di f deve
cadere in
un intorno di f
(ad esempio $|\hat{f} - f| < 0,01$)



Integrando la ddp^* , voglio che l'area nell'intorno
sia almeno il 95% di tutta l'area della ddp

* distribuzione del numero effettivo di persone
intervistate dal sondaggista

formalizziamo il calcolo:
voglio calcolare ...

$$P(|M_n - f| \leq 0,01) \geq 0,95$$

ACCURATEZZA
(PUNTO FORCHETTA)

LIVELLO FIDUCIARIO
(CONFIDENCE LEVEL)

Aumentare n fa aumentare il livello fiduciaro

Quindi per $n \rightarrow +\infty$, Liv. FID. $\rightarrow 1$

Però non posso andare all'infinito $\rightarrow$ Devo trovare il valore n minimo che mi assicura un certo livello fiduciaro...

$$(E[M_n] = p)$$

$$P(|M_n - E[M_n]| \geq 0,01) \leq \frac{\text{var}[M_n]}{(0,01)^2}$$

Applico CHEBYSHEV ε^2


$$\text{Ma } \text{var}[M_n] = \frac{\text{var}[x_i]}{n} = \frac{p(1-p)}{n}$$

$$\Rightarrow P(|M_n - E[M_n]| \geq 0,01) \leq \frac{p(1-p)}{n(0,01)^2}$$

Abbiamo ancora stimare p , come?

Mi basta trovare il valore massimo di $p(1-p)$

Se traccio il grafico di $p(1-p)$, noto che il suo valore massimo è $\frac{1}{4}$



$$\text{Quindi } p(1-p) \leq \frac{1}{4}$$

Sostituendolo nella disuguaglianza di prima

$$P(|M_n - E[M_n]| \geq 0,01) \leq \frac{1}{4n(0,01)^2}$$

Posso imporre

che questo sia $\leq$ al LIVELLO FIDUCIARIO ...

$$\frac{1}{4n(0,01)^2} \leq 1 - 0,95 = 0,05$$

Da cui otteniamo che $n \geq 50000$

Quindi il numero minimo di persone che devo intervistare per raggiungere il livello di fiducia noto è circa 50000

Hmmmmmmmm

... non è un po' troppo alto? Nella vita reale tipicamente ne bastano 1000 ...

Come posso abbassarlo?

- ① Uso un livello fiduciario più piccolo
- ② Uso una forchetta più piccola

PROBLEMA: Si renuncia a un risultato "bravo" perché si ha un errore più grande

- ③ Cambio disuguaglianza: Chebyshev è una disuguaglianza universale (vale per qualsiasi distribuzione), dunque non è la migliore

④ Comerino le precedenti


Proviamo a migliorare Cheb. : riusciamo a trovare una disuguaglianza che funziona meglio sulle V.A. Bern?

Studiamo meglio la media campionaria ...


$$M_n = \frac{x_1 + \dots + x_n}{n} = \frac{S_n}{n} \rightarrow \text{Somma campionaria}$$

Disegniamole su un grafico...


① Disegno f_{x_1} , la ddp di una di queste V.A.



② Disegno f_{S_n} sapendo che $E[S_n] = nE[X_1]$
e $\text{Var}[S_n] = n\text{Var}[X_1]$



③ Dividendo per n trovo f_{M_n}
 quindi $\text{var}[M_n] = \frac{1}{n} \cdot \text{var}[x_1]$



Notiamo che, dividendo per n , otteniamo una
 varianza che forse è un po' troppo piccola

Quindi ci chiediamo se possiamo dividere S_n per
 un valore "intermedio"...

Una possibile soluzione è STANDARDIZZARE S_n ...

$$\frac{S_n - E[S_n]}{\sqrt{\text{var}[S_n]}} = \frac{S_n - n\mu}{\sqrt{n\sigma^2}} = z_n$$

se $E[x_1] = \mu$
 e $\text{var}[x_1] = \sigma^2$
 allora...


Notiamo che...

$$E[z_n] = 0$$

$$\text{var}[z_n] = 1$$

Valori
 indipendenti
 da n !

Disegnando la standardizzazione di S_n (z_n)...



Ora, quando n aumenta, la forma di f_{z_n} può cambiare, ma, INDIPENDENTEMENTE da n , la varianza vale 1 e il valore atteso vale 0

E se $n \rightarrow \infty$? la forma di f_{z_n} a cosa "converge"?

**TEOREMA DI DE MOIVRE-LAPLACE oppure
TEOREMA FONDAMENTALE DEL LIMITE (in inglese
CENTRAL LIMIT THEOREM o CLT)**

Siamo X_i v.a. IID con $\text{var}[X_i] < \infty$ e
sia ...

$$z_n = \frac{X_1 + \dots + X_n - nE[X_1]}{\sqrt{n \text{var}[X_1]}}$$

Sia inoltre $z \sim N(0,1)$. Allora...

$$f_{z_n}(c) \xrightarrow{n \rightarrow +\infty} f_z(c) = \Phi(c)^* \quad \forall c \in \mathbb{R}$$

Questa convergenza è
diversa da quella vista
prima: si chiama

CONVERGENZA IN

DISTRIBUZIONE, proprio

perché è una convergenza
sulle CUMULATE

* la sappiamo
calcolare

quindi per $n \rightarrow +\infty$, la cumulata di z_n diventa
quella di una Gaussiana Standard

Questo è il motivo per cui molti esperimenti
aleatori che ci circondano nella vita reale sono
legati alle Gaussiane...

OSSERVAZIONI:

- ① Il teorema è universale: vale per qualsiasi
legge di prob. X_i (con varianza finita)
- ② Si può usare per fare calcoli approssimati (e
spesso accurati)

Impatti, per $F_{z_n} \rightarrow F_z$, vale che $z_n \approx N(0,1)$
(per n sufficientemente grande)

Questo significa che...

$$z_n = \frac{S_n - n\mu}{\sqrt{n\sigma^2}} \rightarrow S_n = \sqrt{n\sigma^2} z_n + n\mu$$

Ma z_n tende
a z


Quindi $S_n \approx N(n\mu, n\sigma^2)$

Questo significa che per n sufficientemente grande, non bisogna calcolare tutte le convoluzioni.

Invece, si può affermare che, essendo n abbastanza grande, la distribuzione è all'incirca gaussiana

③ Il CLT ci dice qualcosa sulla convergenza della cumulata, e non sulla convergenza della PDF (o della PMF, in caso discreto)

ESEMPIO:




Notiamo che N non deve essere grandissimo:
in questo esempio, l'effetto del CLT si vede
già per $N=8$

Questa cosa non è sempre vera però...

④ la velocità di convergenza alla Gaussiana
dipende dalla forma della legge di probabilità


ESEMPIO 1:

Distribuzione
simmetrica




ESEMPIO 2:



Distribuzione di una geometrica
troncata alla realizzazione 6
=> distribuzione



non
simmetrica!



Questa volta,
per $N=8$,
non siamo
allo stesso
punto di
prima...



per $N \gg 8$ otteniamo una
forma molto simile a una
Gaussiana

In generale, più la distribuzione è asimmetrica,
più la convergenza a una gaussiana è lenta...

Torniamo al problema del sondaggista e proviamo ad applicare il CLT

OBIETTIVO: $P(|M_n - p| \geq 0,01) \leq 0,05$

1°: standardizzo l'evento $M_n = \frac{S_n}{n}$

$$|M_n - p| \geq 0,01 \Rightarrow \left| \frac{S_n}{n} - p \right| \geq 0,01$$

$E[S_n] = np$

$$\rightarrow \left| \frac{S_n - np}{n} \right| \geq 0,01$$

Al denominatore voglio qualcosa tipo $\sqrt{n\sigma^2}$. Posso scrivere che $n = \sqrt{n} \cdot \sqrt{n}$
Posso portare un $\sqrt{n}$ dall'altra parte della disuguaglianza e dividere ambo i membri per σ

$$\Rightarrow \left| \frac{S_n - np}{\sqrt{n} \cdot \sigma} \right| \geq \frac{0,01 \sqrt{n}}{\sigma}$$

$$\sqrt{\text{var}[S_n]} = \sqrt{n\sigma^2}$$

Ho trovato la gaussiana: $z_n = \frac{S_n - np}{\sqrt{n\sigma^2}}$

Quindi...

$$P\left(|z_n| \geq \frac{0,01\sqrt{n}}{\delta}\right) = P\left(|z_n| \geq 0,01\sqrt{\frac{n}{f(1-f)}}\right)$$

$\hookrightarrow \delta^2 = \text{var}[M_n] = f(1-f) \rightarrow$

Come prima, io non conosco f , ma so che al massimo $f(1-f) \leq \frac{1}{4}$

Quindi posso scrivere che...

$$P\left(|z_n| \geq 0,01\sqrt{\frac{n}{f(1-f)}}\right) \leq P\left(|z_n| \geq 0,02\sqrt{n}\right)$$

Adesso posso applicare il CLT...

$$P\left(|z_n| \geq 0,02\sqrt{n}\right) \approx P\left(|z| \geq 0,02\sqrt{n}\right) =$$

$$= 2\left(1 - \Phi\left(0,02\sqrt{n}\right)\right) \leq 0,05$$

$$\rightarrow \Phi\left(0,02\sqrt{n}\right) \geq 0,975$$

uso la tavola $\nearrow$
e cerco i due indici da sommare in modo
che la loro Φ valga 0,975

$$\rightarrow 0,02\sqrt{n} = 1,96 \rightarrow n_{\min} \approx 9604$$

Valore molto più
piccolo di 50000, e molto più
realistico $\nearrow$

