

Applichiamo tutto quello che abbiamo visto in questo corso per introdurre la **TEORIA DELL'INFORMAZIONE**, nata nel secondo - dopoguerra e introdotta da Claude Shannon (l'AI Claude prende il nome da lui)

AUTO-INFORMAZIONE DI UN EVENTO

ESEMPIO: Alice fa un esperimento e vuole comunicare i risultati dell'esperimento a Bob. Quanta **INFORMAZIONE** deve trasmettere Alice?

Notiamo che prima di osservare il risultato dell'esperimento, Alice è **INCERTA** su cosa osserverà. Questa indecisione è descritta da $P(A)$: prob. dell'evento A .

Dopo aver effettuato l'esperimento, sappiamo di aver osservato A ...

- Se A è raro siamo molto "sorpresi"
- Se A è comune non siamo molto "sorpresi"

Vogliamo misurare il livello di sorpresa (o di informazione) portato dall'accadere di A

$$i(A) \triangleq \log \frac{1}{P(A)} \quad \leftarrow \text{AUTO-INFORMAZIONE DI } A$$

Notiamo che:

- Se $P(A) \rightarrow 0$ allora $i(A) \rightarrow \infty$
- Se $P(A) \rightarrow 1$ allora $i(A) \rightarrow 0$

DOMANDA: Che base scelgo per il logaritmo?

Ho varie opzioni:

- base naturale "e": [nat] natural
(Tipico per i matematici)
- base 2: [bit] binary digit (proposto da Shannon)
(Tipico per ingegneri)
- base 10: [Hartley]

ESEMPIO 1: lancio di moneta onesta

$$A = \text{"Testa"} \quad P(A) = 1/2$$

$$\rightarrow i(A) = \log_2 \frac{1}{P(A)} = \log_2 (2) = 1 \text{ bit}$$

ESEMPIO 2: Moneta sbilanciata

$$P(\text{Testa}) = 1/64$$

$$\rightarrow i(\text{Testa}) = \log_2 \frac{1}{1/64} = 6 \text{ bit}$$

$\rightarrow$ Più informazione di prima!

ESEMPIO 3: lancio di un dado a 6 facce

$$A \{ \text{esce la faccia 1} \} \quad P(A) = 1/6$$

$$\rightarrow i(A) = \log_2 6 = 1 + \log_2 3 \text{ bit}$$

Puo' anche essere non intero

RICORDA: stiamo misurando la quantità di informazione, non il numero di bit richiesti

$\rightarrow$ Il valore finale puo' anche non essere intero!

ESEMPIO 4: Stesso esperimento di prima

$$B = \{\text{esce una faccia pari}\}$$

$$\rightarrow i(B) = \log_2 2 = 1 \text{ bit} \quad \text{← Stesso risultato dell'esempio 1}$$

Come nell'esempio 1, la probabilità dell'evento è pari a $1/2$.

Dunque, ai fini dell'informazione, importano solo le probabilità, e non i particolari eventi o esperimenti aleatori.

→ la teoria dell'informazione in questione si dice SINTATTICA e non SEMANTICA

Ma perché abbiamo scelto il logaritmo?

Ho due eventi indipendenti, A e B. Allora...

$$i(A \cap B) = \log \frac{1}{P(A \cap B)} = \log \frac{1}{P(A) \cdot P(B)} = \log \frac{1}{P(A)} + \log \frac{1}{P(B)}$$

Dunque, grazie al logaritmo riusciamo a rispettare proprietà come questa!

ESEMPIO: lancio una moneta bilanciata

A: "Esce testa al 1° lancio"

B: "Esce testa al 2° lancio"

$$A \perp B$$

$$\rightarrow i(A \cap B) = i(A) + i(B) = 1 + 1 = 2 \text{ bit}$$

CONTENUTO INFORMATIVO DI UNA V.A. (DISCRETA)

Per le V.A. continue il discorso è diverso e non lo affronteremo in questo corso

Un esperimento aleatorio è descritto da una V.A. discreta.

A ogni evento elementare associamo una prob. e quindi una autoinformazione...

$$i(\{X=x\}) = i(x) = \log \frac{1}{p_X(x)} \quad \forall x \in \mathbb{R}$$

Se vale $\forall x$ allora posso definire la V.A. ...

$$\text{V.A. INFORMAZIONE} \quad i(X) = \begin{cases} \log \frac{1}{p_X(x_1)} & \text{con prob. } p_X(x_1) \\ \log \frac{1}{p_X(x_2)} & \text{con prob. } p_X(x_2) \\ \vdots \\ \log \frac{1}{p_X(x_n)} & \text{con prob. } p_X(x_n) \end{cases}$$

la domanda che ci si può porre adesso è
"mediamente, quanta informazione estrae Alice dall'esperimento aleatorio?"

Introduciamo, quindi, il concetto di **INFORMAZIONE MEDIA** o **ENTROPIA** della V.A. X

$$H(X) \stackrel{\Delta}{=} E[i(X)] = E\left[\log \frac{1}{p_X(x)}\right] \stackrel{\text{LOTUS}}{=} \\ = \sum_{j=1}^n p_X(x_j) \cdot \log \frac{1}{p_X(x_j)}$$

INTERPRETAZIONE: $H(X)$ è il numero medio di bit di informazione che mi aspetto di ottenere dall'esecuzione dell'esperimento aleatorio

ESEMPIO 1: ENTROPIA di una V.A. DEGENERE.

$X = a$ con probabilità $p_X(a) = 1$

$$\rightarrow i(\{X=x\}) = \begin{cases} \log \frac{1}{1} = 0 & \text{se } x = a \\ \log \frac{1}{0} = ?? & \text{se } x \neq a \end{cases}$$

Quindi ...

$$H(X) = E[i(X)] = p_X(a) \cdot 0 + (1 - p_X(a)) \cdot (??)$$

Questa espressione vale ...

$$\lim_{t \rightarrow 0^+} t \cdot \log\left(\frac{1}{t}\right) = 0$$

Dunque $H(X) = p_X(a) \cdot 0 + 0 = 0$

Quindi $H(X) = 0$, cioè: mediamente, un esp. aleatorio dove non c'è incertezza non genera alcuna informazione (Alice non deve mandare niente a Bob, perché Bob conosce già il risultato dell'esperimento)

OSSERVAZIONE: Non esistono v.a. discrete* con entropia negativa, visto che l'informazione non è mai negativa. In simboli, $H(Y) \geq 0 \quad \forall Y$

* Ci sono v.a. continue con entropia negativa, ma noi non le vedremo

ESEMPIO 2: $X \sim U [x_1, x_2, \dots, x_m]$
 $p_X(x_j) = 1/m \quad \forall j$

Calcoliamo l'autoinformazione...

$$i(x_j) = \log \frac{1}{1/m} = \log(m) \quad \forall j$$


... da cui calcoliamo l'entropia

$$\rightarrow H(X) = E[\log(m)] = \log(m)$$

Per esempio, se $m=2$, allora $H(X) = \log(2)$

PER CAPIRE MEGLIO:

Quale di questi casi ha entropia maggiore?



RISPOSTA:

Escludiamo la prima perché $H(\text{v.a. DEGENERE}) = 0$

Invece, nella seconda $H(x) = \log_2(2) = 1$ bit, la terza avrà un valore minore di entropia, perché la moneta è più sbilanciata.

In generale, la v.a. $U \{x_1, \dots, x_m\}$ è quella con massima entropia. In particolare...


$$H(U \{x_1, \dots, x_m\}) = \log m$$

Qualsiasi altra v.a. discreta Y ha entropia compresa tra 0 e $\log(m)$

DIMOSTRO:

Sappiamo che il logaritmo è concavo.

Quindi, presi due punti, il segmento che li unisce sta "sotto" il grafico del logaritmo



Scriviamo questa cosa in un altro modo...

Sia $x = \lambda x_1 + (1-\lambda) x_2$ con $\lambda \in [0; 1]$. Allora...

$$\forall x \in [x_1, x_2]: \log(x) \geq \lambda \log(x_1) + (1-\lambda) \log(x_2)$$

Partiamo dal dimostrare per un caso base e poi generalizziamo...

CASO $m=2$;

$$\log(x) = \log(\lambda x_1 + (1-\lambda)x_2) \geq \lambda \log(x_1) + (1-\lambda) \log(x_2)$$

Prendiamo $\lambda = p_Y(y_1) \Rightarrow 1-\lambda = p_Y(y_2)$

e scriviamo che $x_1 = \frac{1}{p_Y(y_1)}$ e $x_2 = \frac{1}{p_Y(y_2)}$

$$\Rightarrow \log(2) \geq p_Y(y_1) \cdot \log \frac{1}{p_Y(y_1)} + p_Y(y_2) \log \frac{1}{p_Y(y_2)} = H(Y)$$

CASO GENERALE:

Ora generalizziamo usando la DISEGUAGLIANZA DI JENSEN...

DISEGUAGLIANZA DI JENSEN:

Dati $\lambda_1, \dots, \lambda_m$ t.c. $\sum_{i=1}^m \lambda_i = 1$ e $\lambda_i \geq 0 \forall i$,
vale che...

$$\sum_{i=1}^m \lambda_i \log x_i \leq \log \left(\sum_{i=1}^m \lambda_i x_i \right)$$

Cioè: il logaritmo della media è maggiore della media dei logaritmi

Applichiamo Jensen con $\lambda_i = p_Y(y_i) \forall i$

e $x_i = \frac{1}{p_Y(y_i)} \forall i$

$$\sum_{i=1}^m p_Y(y_i) \cdot \log \frac{1}{p_Y(y_i)} = \log \left(\sum_{i=1}^m p_Y(y_i) \cdot \frac{1}{p_Y(y_i)} \right)$$

Definizione di $H(Y)$

$$\rightarrow H(Y) = \log(m)$$

In particolare $H(Y) = \log(m)$ se e solo se la
V.A. $Y \sim U\{y_1, \dots, y_m\}$

Quindi $H(Y) = \log(m)$ quando
 Y è distribuita uniformemente...
 $Y \sim U[y_1, \dots, y_m]$



In generale, la **DISEGUAGLIANZA DI JENSEN**
vale per qualsiasi funzione concava e convessa:

- Se la funzione f è concava...

$$E[f(Y)] \leq f(E[Y])$$

(per questo motivo abbiamo detto che non
si poteva RAGIONARE IN MEDIA

- Se la funzione f è convessa...

$$E[f(Y)] \geq f(E[Y])$$

↑
occhio al verso della disuguaglianza!

ESEMPIO 1: lancio una moneta, $P(T) = p$
con $0 \leq p \leq 1$


$$\text{Quindi } X = \begin{cases} 1 & \text{con prob. } p \\ 0 & \text{con prob. } 1-p \end{cases}$$

$$\Rightarrow i(X) = \begin{cases} \log \frac{1}{p} & \text{con prob. } p \\ \log \frac{1}{1-p} & \text{con prob. } 1-p \end{cases}$$

$$\rightarrow H(X) = E[i(X)] = p \log \frac{1}{p} + (1-p) \log \frac{1}{1-p} =$$

$$= H(\text{Bern}(p)) \triangleq H_b(p) \leftarrow \text{BINARY ENTROPY FUNCTION}$$

GRAFICO:



PROPRIETA' IMPORTANTE:

$$\lim_{\substack{p \rightarrow 0 \\ p \rightarrow 1}} \frac{d}{dp} H_b(p) = \infty$$

ESEMPIO 2: Sia X : # di lanci di moneta
rilanciata fino a ottenere T , con $P(T) = 1/2$

Sappiamo, quindi, che $X \sim \text{Geom}(P(T) = 1/2)$

$$\rightarrow p_X(k) = \left(\frac{1}{2}\right)^k \quad \text{per } k = 1, 2, 3, \dots$$

$$\rightarrow i(\{X=k\}) = \log_2 \frac{1}{1/2^k} = k \text{ bit}$$

calcoliamo
l'autoinformazione in bit

$$\rightarrow i(X) = X$$

$$\rightarrow H(X) = E[i(X)] = E[X] = 2 \text{ bit}$$

² Geom(1/2)

Quindi, prima di fare
l'esperimento aleatorio, so già che riceverò
in media 2 bit di informazione
